

# CYK Probabiliste

Lapraye & Lévêque & Viegas

Paris VII

30 juin 2016

# L'Algorithme CYK

- Un algorithme de parsing ascendant

# L'Algorithme CYK

- Un algorithme de parsing ascendant
- Complexité  $\mathcal{O}(|G|n^3)$

# L'Algorithme CYK

- Un algorithme de parsing ascendant
- Complexité  $\mathcal{O}(|G|n^3)$
- Parsing tabulaire

# L'Algorithme CYK

- Un algorithme de parsing ascendant
- Complexité  $\mathcal{O}(|G|n^3)$
- Parsing tabulaire
- Extension aux grammaire hors-contexte probabilistes (PCFG)

# L'Algorithme CYK

```
function CKY( $w[1..n]$ ,  $G :< NT, T, P, \rho >$ ,  $R[1..n, 1..n]$ )
  for all  $i$  de 1 à  $n$  do
    if  $N \rightarrow w_i$  then
       $R[i, i+1] \leftarrow N$ 
    end if
  end for
  for all  $k$  de 2 à  $n$  do
    for all  $i$  de 1 à  $n - i + 2$  do
      for all  $j$  de  $i+1$  à  $i+k$  do
        for all  $A \in R[i, j]$  do
          for all do
            for all  $NT \in P$  do
              if  $NT \rightarrow AB$  then
                 $R[i, i+k] = R[i, i+k] \cup \{NT\}$ 
              end if
            end for
          end for
        end for
      end for
    end for
  end for
  if  $S \in R[0, n]$  then return True
end if
end function
```

# L'Algorithme CYK

- Les CFG : un quadruplet  $(\Sigma, V, S, P)$



# Les PCFG

- Les CFG : un quadruplet  $(\Sigma, V, S, P)$
- Les CFG pondérées : ajout d'une fonction de poids  
 $f : p \mapsto \alpha, w \in W, \alpha \in \mathbb{R}$

- Les CFG : un quadruplet  $(\Sigma, V, S, P)$
- Les CFG probabilistes : les poids correspondent à des probabilités pour une réécriture donnée.

$$f : p \mapsto \alpha, p \in P, \alpha \in [0, 1]$$

$$\forall X \in V, \sum_{X \rightarrow \alpha} p(X \rightarrow \alpha) = 1$$

- Les CFG : un quadruplet  $(\Sigma, V, S, P)$
- Les CFG probabilistes : les poids correspondent à des probabilités pour une réécriture donnée.

$$f : p \mapsto \alpha, p \in P, \alpha \in [0, 1]$$

$$\forall X \in V, \sum_{X \rightarrow \alpha} p(X \rightarrow \alpha) = 1$$

- Les CFG probabilistes représentent un modèle de prédiction déduit à partir du corpus dont elles sont extraites.

- Les CFG : un quadruplet  $(\Sigma, V, S, P)$
- Les CFG probabilistes : les poids correspondent à des probabilités pour une réécriture donnée.

$$f : p \mapsto \alpha, p \in P, \alpha \in [0, 1]$$

$$\forall X \in V, \sum_{X \rightarrow \alpha} p(X \rightarrow \alpha) = 1$$

- Les CFG probabilistes représentent un modèle de prédiction déduit à partir du corpus dont elles sont extraites.
- Extraction des PCFG

# La forme normale de Chomsky (CNF)

- l'axiome  $S$  est inaccessible
- Les règles de production adoptent une des formes suivantes, avec  $\varepsilon$  la production vide,  $A, B, C, D \in V$ , et  $e \in \Sigma$  :

$$A \rightarrow BC$$

$$D \rightarrow e$$

$$S \rightarrow \varepsilon$$

# Transformer la grammaire en CNF

- 1 Faire en sorte que l'axiome n'apparaisse plus dans les parties droites de règles
- 2 Supprimer les règles d'effacement (c'est à dire de la forme  $A \rightarrow^* \varepsilon$ ) pour les non-terminaux autres que l'axiome.
- 3 Faire en sorte que tout les terminaux apparaissent uniquement dans la partie droite de règles unaires
- 4 Remplacer les règles de production n-aire par des règles binaires équivalentes.
- 5 Supprimer les productions singulières de non-terminaux, c'est à dire les règles de la forme  $A \rightarrow B$  avec  $A, B \in V$

# Transformer la grammaire en CNF

- 1 Faire en sorte que l'axiome n'apparaisse plus dans les parties droites de règles
- 2 Supprimer les règles d'effacement (c'est à dire de la forme  $A \rightarrow^* \varepsilon$ ) pour les non-terminaux autres que l'axiome.
- 3 Faire en sorte que tout les terminaux apparaissent uniquement dans la partie droite de règles unaires
- 4 Remplacer les règles de production n-aire par des règles binaires équivalentes.
- 5 Supprimer les productions singulières de non-terminaux, c'est à dire les règles de la forme  $A \rightarrow B$  avec  $A, B \in V$

# Le corpus Sequoia

- Un corpus diversifié
- Des phrases de longueur variable
- Extraction de la grammaire






# Notre implémentation du CYK





# Evaluation

# Références

 Brian Roark, Richard Sproat.  
*Computational Approaches to Morphology and Syntax*.  
Oxford University Press, 2007.

 Mariana Romanyshyn, Vsevolod Dyomkin.  
*The Dirty Little Secret of Constituency Parser Evaluation*, 2014.  
<http://tech.grammarly.com/blog/posts/The-Dirty-Little-Secret-of-Constituency-Parser-Evaluation.html>

 Martin Lange, Hans Leiss  
« To CNF or not to CNF : An Efficient Yet Presentable Version of the CYK Algorithm », 2009  
*Informatica Didactica* N° 8

 E. Black, S. Abney et al.  
« Procedure for Quantitatively Comparing the Syntactic Coverage of English Grammars »  
1991, DARPA Speech and Natural Language Workshop